MEMORY / 26

人工智能发展背景下的内存需求与市场变化研究

SPEAKERS

12

SLIDES

65

RUNTIME

45 min

MEMORY DEMAND & MARKET CHANGE

齐景睿　宋明喆　万丰睿　莫镇豪　郭宸瑞　范彦龙
高一涵　王皓正　王劭　王珂鸣　岳梓航　张舒予

信息科技综合研究　2026.10.19

主持人　万丰睿

地表最豪小组

内存条是什么

它是 CPU 的工作台，不是仓库

本段关键词

DRAM 颗粒 · 金手指 · 尺寸

齐景睿

断电就清空，
所以它只放“正在用”的东西

长期保存，是硬盘的事，而硬盘决定“还能不能找回来”

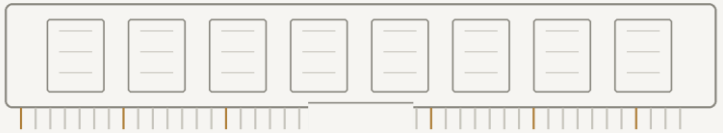


图　DDR5 模组结构 · 本文绘制

八颗 DRAM 颗粒焊在 PCB 上，底部金手指和插槽交换数据；中间的缺口决定它插得进哪种主板。

一根内存条里有什么

01	DRAM 颗粒	真正存数据的地方，一颗一颗焊在 PCB 上
02	金手指	和主板交换数据的触点，代际不同插不进去
03	尺寸	长 133 mm，立起来 31 mm



图　内存条 31 mm vs 硬币 25 mm · 本文绘制

把内存条立起来，比一枚一元硬币（直径 25 mm）还高 6 毫米——参照物选对了，尺寸才有体感。SPD 芯片记录时序与容量，主板开机时先读它，再决定以什么速度跑。

买内存 = 容量 + 速度 + 兼容

只看容量，是最常见的一次踩坑；内存是工作台，硬盘是仓库，混用这两个词就会买错

NEXT

→ 下一位

AI 是什么

宋明喆

一句话

它在做一件事：预测下一个词

第 07 页起

AI 是什么

它在做一件事：预测下一个词

本段关键词

7B · 2 字节 · 1 个

宋明喆

每一次回答，
都是一次超大规模的矩阵乘法

看起来像聊天，算起来是算术，不是“懂语言”，而是“会算概率”

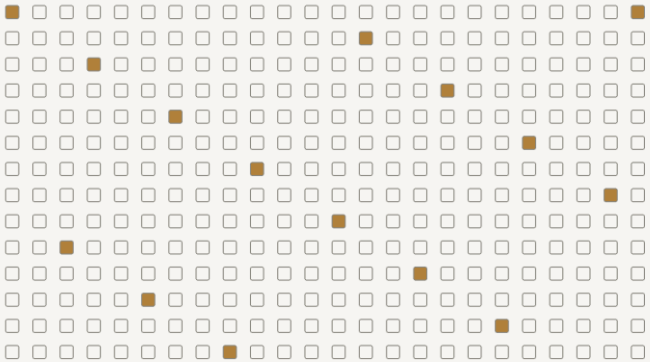


图　参数矩阵 · 本文绘制

每个方格是一组参数。模型越大，一次推理要搬运的权重就越多，瓶颈从算力转向带宽。

AI 的三个数字

起步的参数量

7B

FP16 下一个参数的大小

2 字节

每次只生成一个 token

1 个

70 亿参数 × 2 字节 ≈ 14 GB（13.0 GiB）；上下文 4096→8192→16384 时，KV 缓存约 2 GiB→4 GiB→8 GiB。

AI 的能力来自参数，
AI 的成本也来自参数

这就是它和内存扯上关系的地方；算得快不快，取决于数据搬得快不快

NEXT

→ 下一位

CS 吃 CPU 还是内存条

万丰睿

一句话

官方最低配置写的是“三件套”

第 12 页起

CS 吃 CPU 还是内存条

官方最低配置写的是“三件套”

本段关键词

4 · 8 GB · 1 GB+

万丰睿

官方最低配置，写的是“三件套”

不是只写内存，也不是只写 CPU，而是三件套：线程、内存、显存

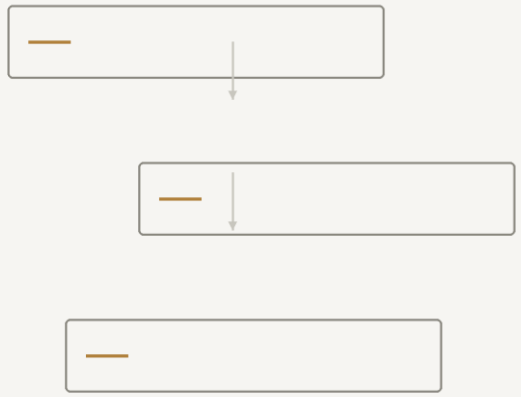


图　存储层级 · 本文绘制

CPU 拿 DRAM 当工作区，SSD 负责断电后保存。容量、带宽、时延是三个不同指标。

CS2 最低配置（Windows）

个硬件 CPU 线程

4

系统内存

8 GB

显卡显存

1 GB+

还要 DX11 / SM 5.0 与 85 GB 磁盘空间；这是运行门槛，不是帧数保证。

没有“吃内存”这回事，只有“卡在哪”

最低配置只是门槛，不是帧数保证；官方配置是下限，不是你的目标帧数

NEXT

→ 下一位

怎么找到真瓶颈

莫镇豪

一句话

先测，再买

第 17 页起

怎么找到真瓶颈

先测，再买

本段关键词

帧时间 · CPU 单核 · GPU 利用率

莫镇豪

地表最豪小组

把“吃 CPU 还是内存”换成“谁在限制帧生成”

前者是争论，后者能测量：谁的等待时间最长，就先修谁

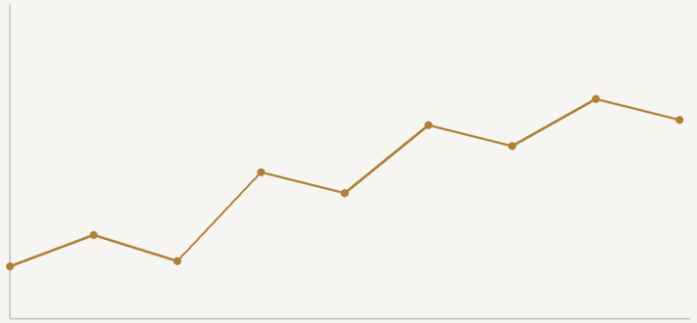


图　帧生成时间 · 本文绘制

帧时间的波动比平均帧率更能说明卡顿：平均 60 帧也可能每两秒卡一次。

四个观察点

01	帧时间	比平均帧率更诚实
02	CPU 单核	总占用率会骗人
03	GPU 利用率	是不是已经打满
04	内存与磁盘	换页就是信号

四个数要同时看：只看 CPU 总占用，会漏掉单核瓶颈；1% 低帧比平均帧率更能说明卡顿。

加内存解决容量，不解决帧率

固定变量、一次只改一个、重复测；先记录再加钱，比先加钱再猜更省钱

NEXT

→ 下一位

AI 如何影响我们的生活

郭宸瑞

一句话

方便在前台，成本在后台

第 22 页起

AI 如何影响我们的生活

方便在前台，成本在后台

本段关键词

调用次数 · 机房 · 电与水

郭宸瑞

推荐、导航、修图、客服，背后都在跑模型

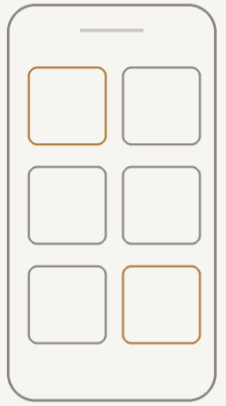


图 AI 服务调用路径 · 本文绘制

你已经用了很久，只是没看见，从推荐到修图，一次调用背后是一整条链路

推荐、导航、修图、客服，每个功能都要把数据送到机房里的模型上，再传回手机。

看不见的三件事

01	调用次数	一天里，模型被问了多少次
02	机房	每一条回答都发生在某台服务器上
03	电与水	算力有价格，也有环境成本

一次调用 = 网络 + 调度 + 算力 + 散热，成本藏在机房里；调用次数 × 单次能耗，决定了“免费”功能背后的电费与机房开销。

AI 不是免费的，
它只是换了个地方寄账单

账单最终会落到硬件、能源和价格上；看不见的部分，才是成本真正发生的地方

NEXT

→ 下一位

谁在控制电子市场

范彦龙

一句话

三家，87.6%

第 27 页起

谁在控制电子市场

三家，87.6%

本段关键词

三星 · SK hynix · 美光

范彦龙

2026 年第二季度 全球 DRAM 营收份额

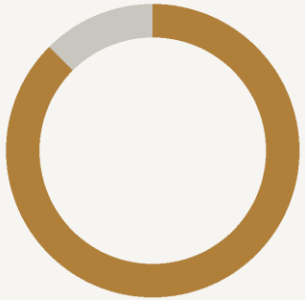


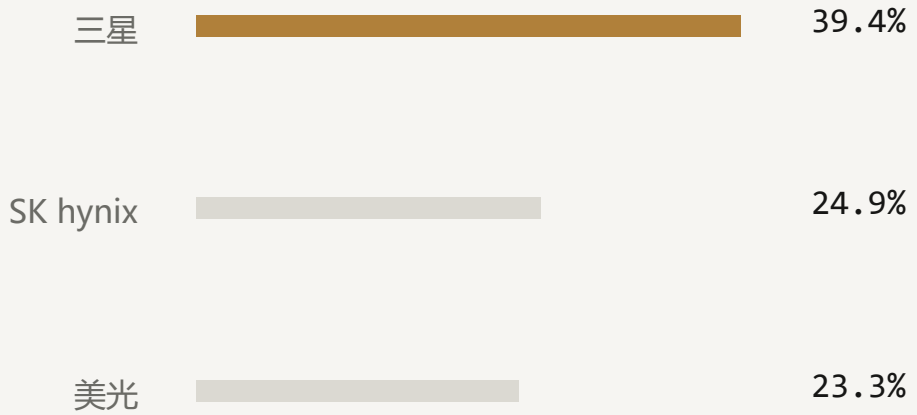
图　头部厂商份额 · TrendForce 2026-09-07

营收口径，不是出货量，也不是零售销量，前三家合计 87.6%，其余 12.4%

弧长按 2026 年第二季度营收份额绘制；其余 12.4% 由其他厂商分走，口径不是出货量。

87.6%

前三家营收份额合计
其余 12.4% 由其他厂商分走



集中度高，不等于合谋；但议价权是真实存在的 营收份额受高价 HBM 拉动，与出货量份额不是同一个指标

集中度不等于垄断，但它决定了谁先拿到货

三家扩产与否，比任何一家都重要；份额高说明议价权，不直接说明有违法行为

NEXT

→ 下一位

AI 为什么让内存涨价

高一涵

一句话

机制成立，因果要留余地

第 32 页起

AI 为什么让内存涨价

机制成立，因果要留余地

本段关键词

AI 服务器需求 · 抢占先进制程 · 其他 DRAM 收紧

高一涵

地表最豪小组

AI 不是来买内存条的

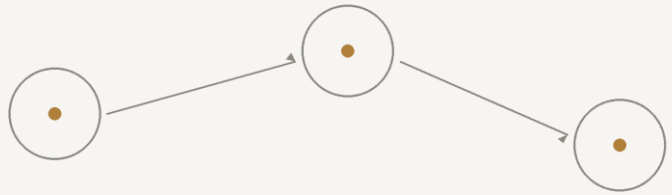


图　产能传导路径 · 本文绘制

它买的是 HBM，挤的是同一条产线

AI 需求先推高 HBM，再沿着同一批晶圆产能传导到其他 DRAM，中间隔着扩产和验证的时间。

三步传导

01	AI 服务器需求	HBM 与高容量服务器内存
↓		
02	抢占先进制程	晶圆和产能是同一批
↓		
03	其他 DRAM 收紧	消费级产品被挤到后面

2026-09 机构预测 4Q26 一般 DRAM 合约价环比 +10–15%；同期还有 DDR4 退市与渠道库存。

能解释“为什么可能涨”，不能解释“涨了多少”

机制是机制，因果是因果；传导成立，但幅度仍受库存与需求周期调节

NEXT

→ 下一位

如何让内存条降价

王皓正

一句话

没有一招见效

第 37 页起

如何让内存条降价

没有一招见效

本段关键词

扩产 · 提良率 · 多一个玩家

王皓正

地表最豪小组

降价只有三条路：扩产、提良率、多一个玩家

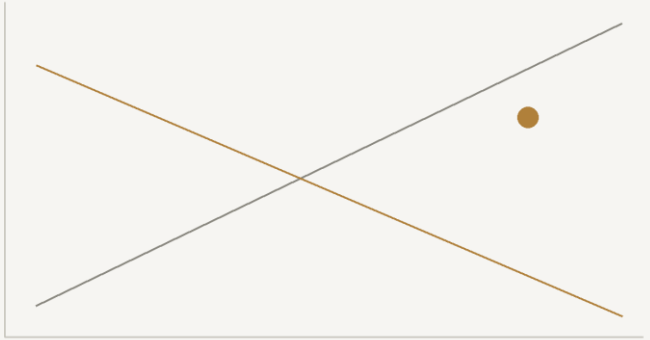


图　供需与价格 · 本文绘制

扩产把供给曲线往右推，价格才下得来；促销只是在同一条曲线上移动。

三条路之外的降价，多半是渠道与促销的短期波动

三条路，都要时间

01	扩产	建厂、装机、爬坡，以年计
02	提良率	同样的晶圆，产出更多好片
03	多一个玩家	有竞争，价格才有下行压力

三条路都需要时间：扩产以年计，良率以季度计，新玩家要过客户验证。

价格是结果，
供给才是原因

指望某一项措施立刻降价，通常要失望；渠道与促销只能改标价，改不了供给

NEXT

→ 下一位

中国存储走到哪一步

王劭

一句话

从能造到好用，中间隔着验证

第 42 页起

中国存储走到哪一步

从能造到好用，中间隔着验证

本段关键词

2025.11 · DDR5 · 3 类

王劭

长鑫 2025 年 11 月展示 DDR5 与 LPDDR5X

覆盖服务器、工作站与个人电脑三类产品

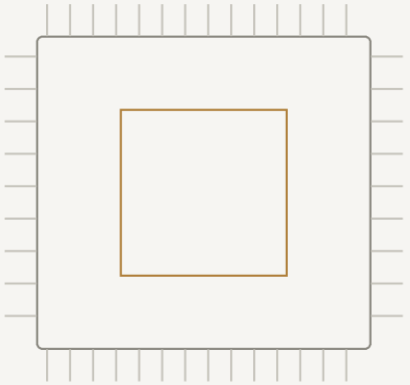


图　颗粒与封装 · 本文绘制

一片晶圆切出很多颗 die，封装成颗粒再焊到模组上——每一层都有损耗，也都有成本。

三个关键词

公开亮相的时间

2025.11

主流代际，不是落后产品

DDR5

服务器 / 工作站 / PC

3 类

产品覆盖在扩，但发布不等于大规模量产 展示产品与稳定供货之间，还隔着良率、认证与客户导入

发布会是开始，量产才是答案

能造出来，和能稳定供货，是两件事；发布是信号，量产才是能力

NEXT

→ 下一位

差距到底在哪

王珂鸣

一句话

三个硬指标

第 47 页起

差距到底在哪

三个硬指标

本段关键词

良率 · 设备与材料 · 客户验证

王珂鸣

差距不在发布会上，在产线上

参数表上的数字，和客户手里的良率不是一回事

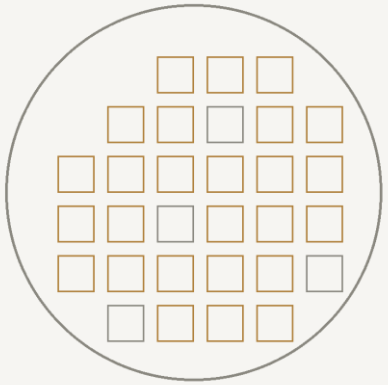


图　晶圆良率 · 本文绘制

金色是合格 die，灰色是报废的；良率每差一个百分点，单位成本就上一个台阶。

绕不开的三关

01	良率	同样的投入，能产出多少合格品
02	设备与材料	先进制程、高带宽封装，处处是门槛
03	客户验证	兼容性、可靠性、成本、交付

三关是串联的：良率决定成本，设备决定扩产，验证决定能不能进供应链。

量产和良率，
才是真正的答案

能替代多少，由客户的下单与退货率决定；产线讲成本，不讲故事

NEXT

→ 下一位

如何摆脱外部控制

岳梓航

一句话

一条管制，管到哪一步

第 52 页起

如何摆脱外部控制

一条管制，管到哪一步

本段关键词

常见误解 · 控制全世界内存 · 普通内存条被禁售

岳梓航

2024 年 12 月 2 日
美国 BIS 出口管制

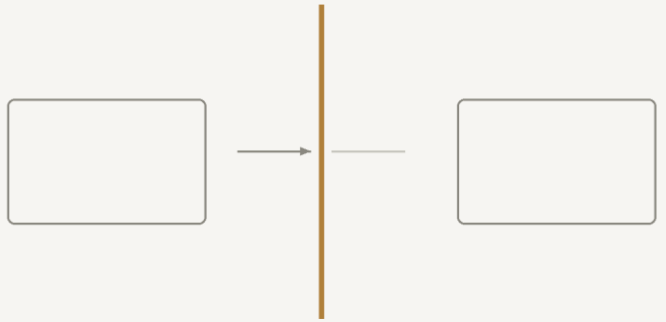


图　管制的落点 · 本文绘制

24 类半导体制造设备、3 类软件工具，以及 HBM

管制落在设备、软件和 HBM 这类先进环节，不是整条供应链的总开关。

三种常见误解

01	控制全世界内存	供应横跨韩国、美国等多个国家
02	普通内存条被禁售	管制落在先进制造环节
03	一条公告=全部法规	这是历史案例，不是现行法规全量

判断政策看三样：范围、生效日期、豁免条款；标题往往比原文激烈。

影响先进环节，不等于全面禁售

应对方式不是口号，是多元供应、自主验证：多来源采购、验证做在前面

NEXT

→ 下一位

十三个人，一个结论

张舒予

一句话

技术、市场、政策，三条线

第 57 页起

十三个人，一个结论

技术、市场、政策，三条线

张舒予

性能看瓶颈，不看参数表

先测再买，是这一条最实用的版本：瓶颈、供给、口径

AI 影响供给，但不是唯一原因

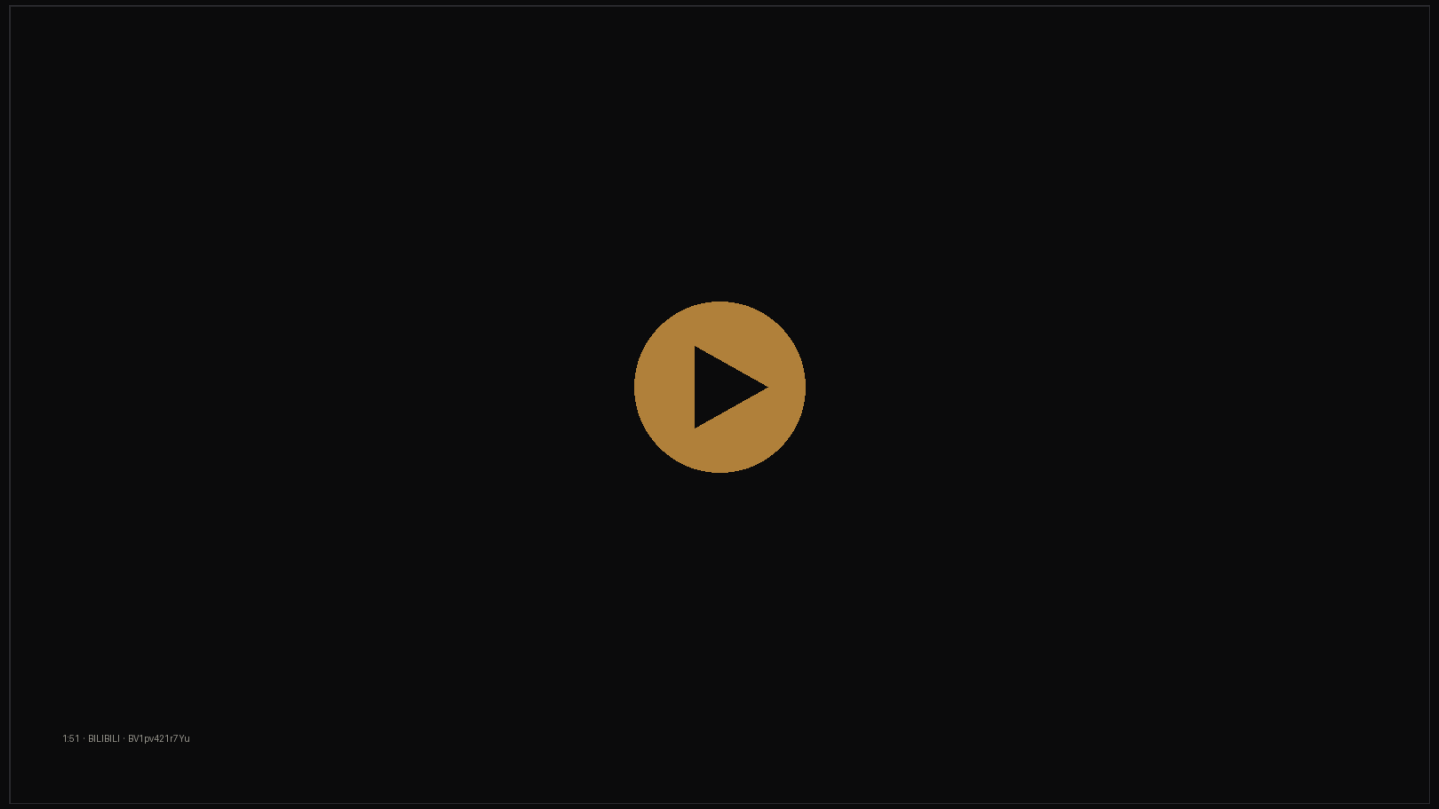
价格还受库存、退市、备货和竞争影响

价格必须带上
对象、时间和口径

合约价不是零售价，预测不是结果；把这三句话记住，比记住任何一个数字都有用

一年前 AI，一年后 AI

内嵌视频 · 1:51



来源

哔哩哔哩 UP 主 夜清月明

BV1pv421r7Yu　1 分 51 秒

用途

说明公众对 AI 能力变化的直观感受，作为讨论起点；它不替代数据与文献。

bilibili.com/video/BV1pv421r7Yu

先按 1 下获得焦点，再点播放；空格暂停

刚才那段视频

视频里的 AI，是 2024 年 2 月的 AI：生成几秒画面，还会穿帮。

你刚才看到的，是 2026 年 10 月的 AI：它把一场研究做完了。

它能读图、能听懂话、能看视频。

它会查资料、写代码、跑验证。

它也会错——所以最后签字，仍然是人。

那么——这一切，是谁做的？

翻到下一页。

以上 65 页幻灯片 · 15 页论文 · 7500 字讲稿 · 动画 · 配乐，全部由

DeepSeek-V4.1-Flash 1017 max

与

ChatGPT6 Astra ultra

制作

你刚才看到的每一页、每一个数字、每一张图，都是 AI 做的。

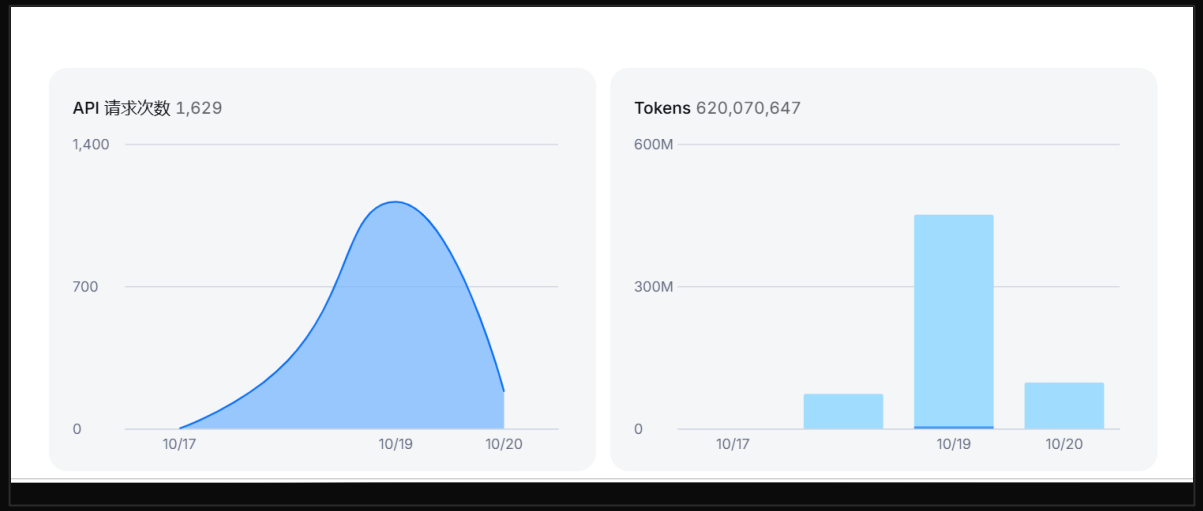
这次作业的体量

把一场研究，拆成几亿次判断。

1,629
API 调用

620,070,647
Tokens

平均每次调用 ≈ 380,645 个 token
（620,070,647 ÷ 1,629 ≈ 380,645）
四天里 1,629 次调用——一场研究被拆成一千多步。



API 控制台 · 请求次数与 tokens · 10/17–10/20（截图为 10/20 时点）

模型 API（匿名）· 2026-10-17 至 10-20
数据来自 API 控制台截图

谢谢

Q&A　地表最豪小组 · 12 位讲者

资料：Valve · NVIDIA · TrendForce · 美国 BIS

访问日期 2026-10-18

音乐：Mixkit 免费音乐 · 12 首（轻柔版）

本次研究 100% 由 AI 生成

研究选题拆解、数据检索、文稿、图表绘制、幻灯片与演讲稿均由 AI 完成；人工仅做方向确认。

全部资料已开源　github.com/nwfm9jjbfy-lgtm/ai-memory-research